Program do segmentacji i rozpoznawania tekstu ze skanów kart promocyjnych

Studio projektowe 1

Dominik Baran
Paweł Caryk

31 maja 2017

Spis treści

1 Opis projektu

Celem projektu było stworzenie narzędzia do automatycznego odczytywania i rozpoznawania kluczy ze skanów/zdjęć. Program poprzez wstępną filtrację skanu, eliminację zakłóceń, a następnie segmentacje otrzymujemy obrazy poszczególnych znaków w kluczu. Do rozpoznawania poszczególnych liter użyliśmy dwóch podejść: sieci neuronowej i SVM. Wykorzystaliśmy zbiór treningowy, który posiadał 2 tys. skanów (łącznie 25 000 liter). Udało się nam również wytrenować rekurencyjną sieć neuronową, która w przeciwieństwie do SVM i zwykłej sieci, rozpoznaje cały klucz od razu (nie jest wymaga segmentacja poszczególnych liter).

2 Techniczne aspekty projektu

2.1 Struktura projektu

W projekcie wykorzystaliśmy kilka języków i frameworków:

- C# - wybraliśmy go głównie ze względu na prostotę stworzenia GUI. Wykorzystaliśmy tutaj framework Python .NET, który umożliwia wywoływanie kodu Pythona z C#
- C++ - przy przetwarzaniu sporej ilości danych wymagaliśmy dużej szybkości dlatego wybraliśmy C++ i framework OpenCV do trenowania SVM i przeprowadzania segmentacji skanów
- Python - wykorzystaliśmy framework TensorFlow i Numpy, które znacznie upraszczają tworzenie, trenowanie i testowanie sieci neuronowej.

Całość wykonaliśmy w IDE Visual Studio 2017. Solucja zawiera następujące projekty:

- CodesReader C# - nasze GUI aby łatwiej można było obserwować rezultaty naszej pracy
- CodesReaderNative C++ - segmentacja i filtracja skanów przy użyciu OpenCV
- OpenCvSVM C++ - trenowanie oraz testowanie modeli SVM przy użyciu OpenCV
- SharedDotNet C# - projekt zawiera interfejsy i klasy abstrahujące logikę rozpoznawania skanów.
- TensorFlowRunner i TensorFlowTrening Python - oba projekty były odpowiedzialne za trenowanie/testowanie sieci neuronowych
- TesseractOCR C# - nieudana próba wykorzystania OCR do rozpoznania skanów (bardzo słaba skuteczność)

2.2 Wygląd GUI

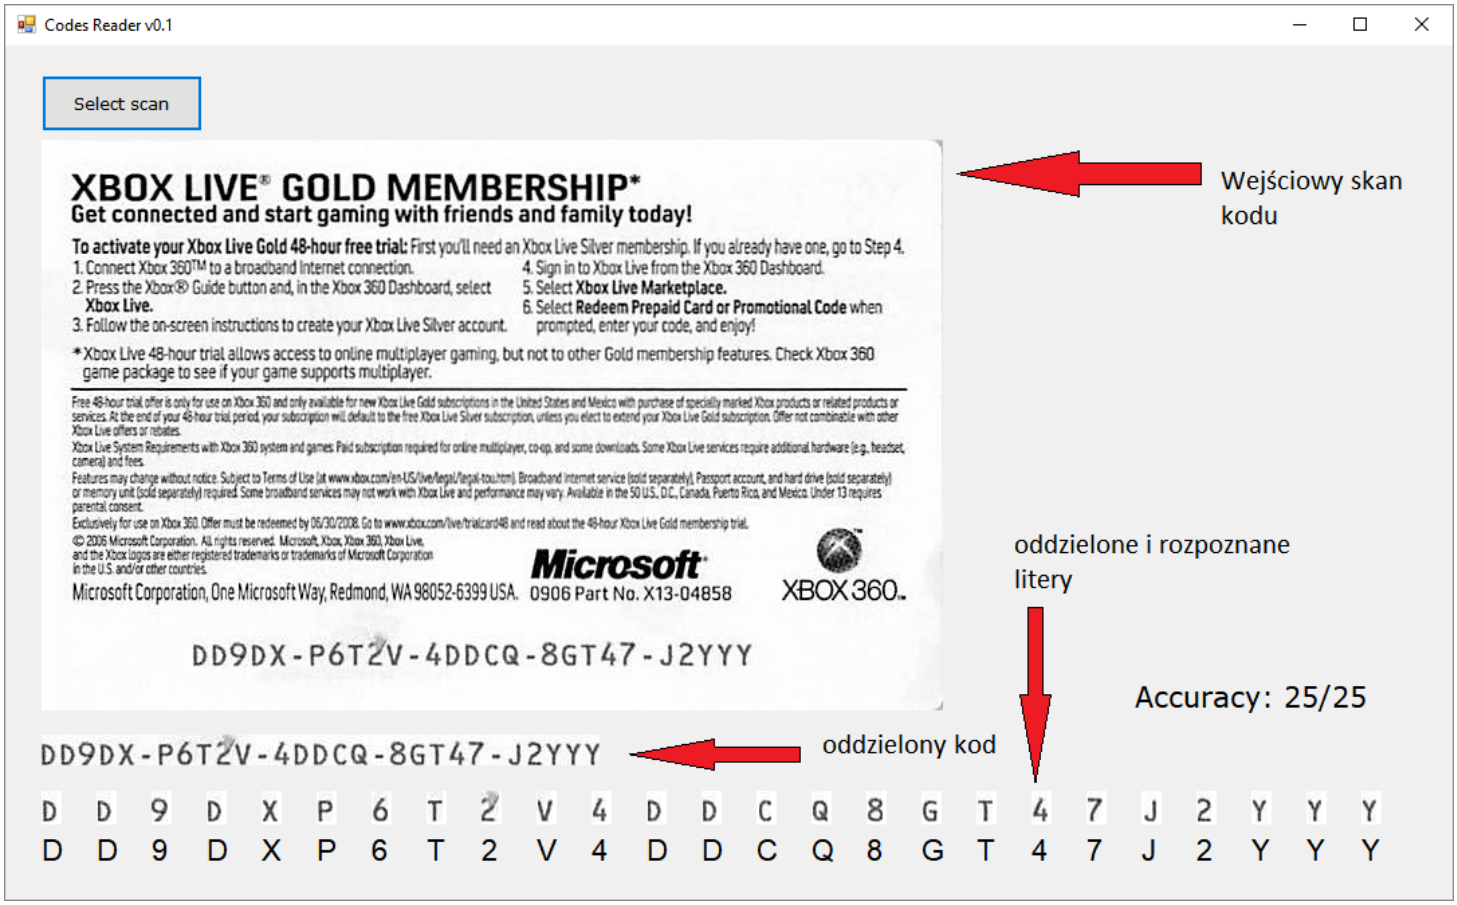

3 Implementacja

3.1 Segmentacja i filtracja skanów

Segmentacja kodu polegała na przeprowadzeniu następujących operacji na bitmapie:

1. Threshold ze stałym progiem (204 i 153)
2. Usunięcie zanieczyszczeń (obiektów mniejszych niż 8 połączonych pikseli)
3. Operacja morfologiczna: otwarcie z obiektem strukturalnym o rozmiarze 45x1. Dzięki temu tekst był rozciągnięty tylko w płaszczyźnie poziomej.
4. Czyszczenie brzegu - dzięki tej operacji usuwaliśmy niepotrzebny tekst ze skanu

5. Operacja morfologiczna: otwarcie z elementem strukturalnym o rozmiarze 1x5. Dzięki temu uzupełnialiśmy drobne pionowe szczeliny

6. Wyszukanie największego obiektu na obrazie dawało poszukiwany kod

Segmentacja poszczególnych liter polegała na przeprowadzeniu następujących operacji na bitmapie:

1. Adaptive threshold

2. Usunięcie zanieczyszczeń (obiektów mniejszych niż 8 połączonych pikseli)

3. Operacja morfologiczna: otwarcie z obiektem strukturalnym o rozmiarze 1x7. Dzięki temu tekst był rozciągnięty tylko w płaszczyźnie pionowej.

4. Wyodrębnienie obiektów, które dotykały górnej i dolnej krawędzi obrazka dawało nam poszczególne litery

3.2 SVM i sieć neuronowa

Do trenowania wykorzystaiśmy 2000 ręcznie przepisanych skanów (łącznie 50 000 liter). Validation set stanowił 20% zbioru treningowego. Trenowanie SVM przeprowadziliśmy przy pomocy biblioteki OpenCV. Wykorzystaliśmy tzw grid search aby znaleźć jak najlepsze parametry dla naszego modelu. W wyniku otrzymaliśmy następujące wartości:
Funkcja: wielomian 3 stopnia
Gamma (jak bardzo jeden przykład wpływa na postęp uczenia) : 0.1
Współczynnik0: 1.0
C (jak bardzo każemy SVM za błędne klasyfikacje): 1.0
Trenowanie rekurencyjnej jak i zwykłej sieci neuronowej polegało głównie na eksperymentowaniu w ilości warstw, ilości neuronów w poszczególnych warstwach, sposobu ich łączenia oraz zmian parametrów uczenia (learning rate itd). Całość wykonaliśmy przy użyciu frameworka TensorFlow. Po wybraniu sieci, która najlepiej się sprawowała na validation set zapisywaliśmy jej model. Następnie porównywaliśmy ją z wcześniej opisanym SVM.

4 Przykłady wyników

4.1 Przykład 1

Zdjęcia przedstawiają kolejno: SVM, sieć neuronową oraz rekurencyjną sieć neuronową. Najlepiej poradziła sobie sieć neuronowa.

Rysunek 1: Przykład 1 - SVM

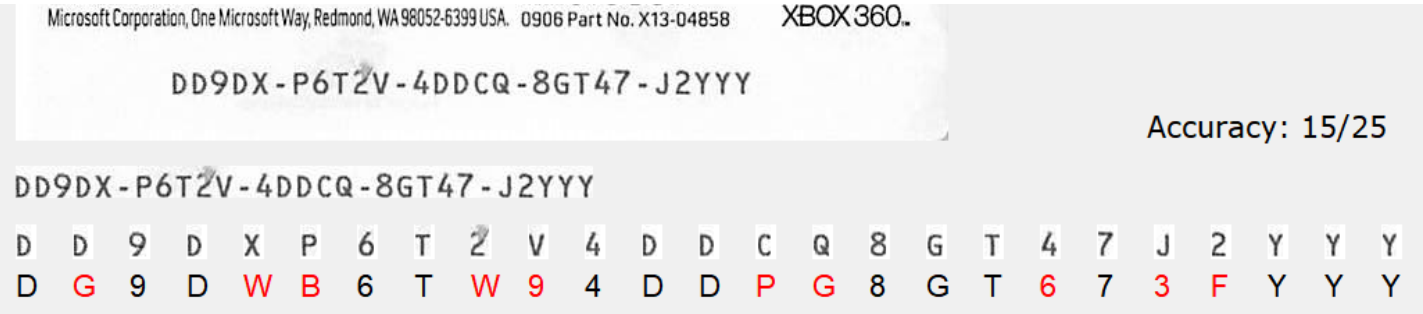

Rysunek 2: Przykład 1 - NN

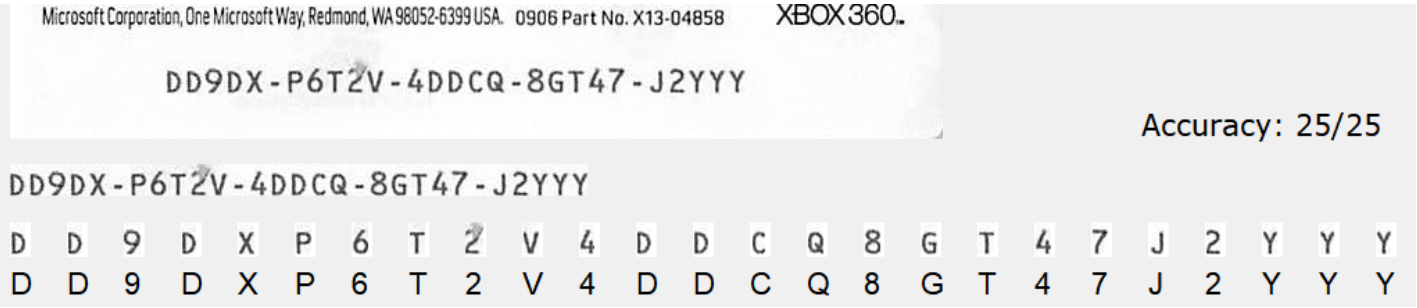

Rysunek 3: Przykład 1 - RNN

4.2 Przykład 2

Zdjęcia przedstawiają kolejno: SVM, sieć neuronową oraz rekurencyjną sieć neuronową. Najlepiej poradziła sobie rekurencyjna sieć neuronowa, która mimo zniekształceń była w stanie rozpoznać nawet rozmazane znaki.

Rysunek 4: Przykład 2 - SVM

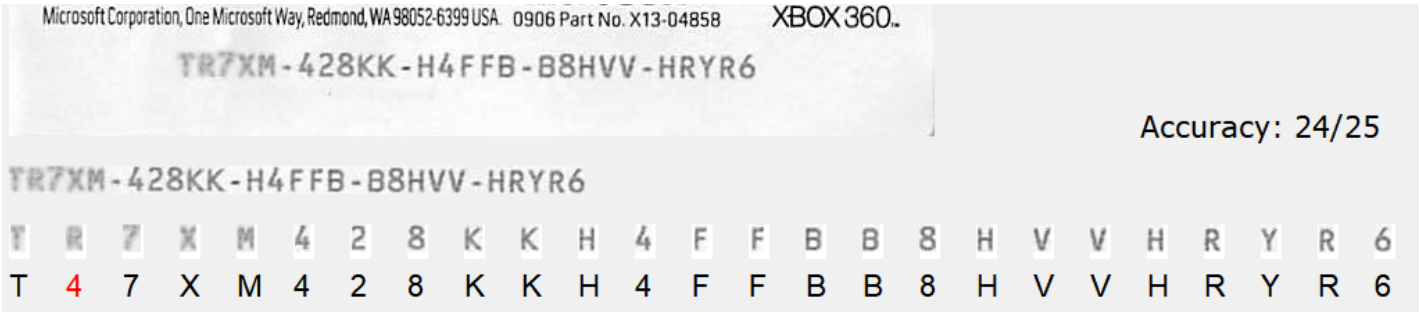

Rysunek 5: Przykład 2 - NN

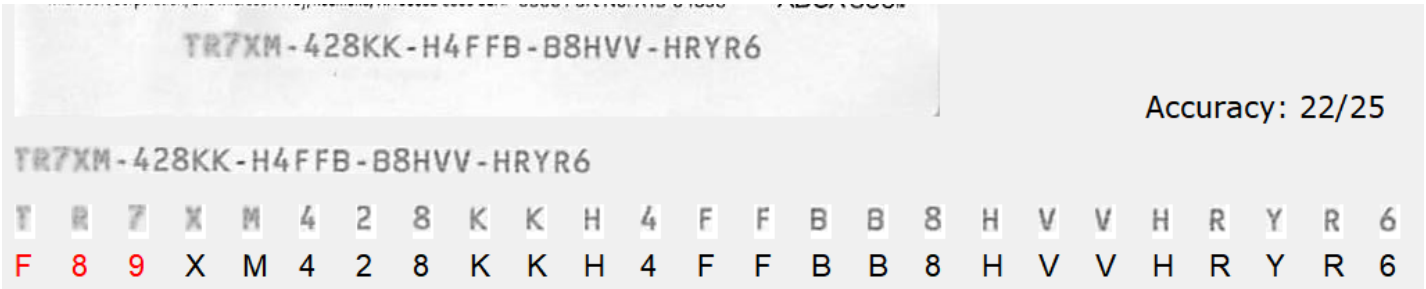

Rysunek 6: Przykład 2 - RNN

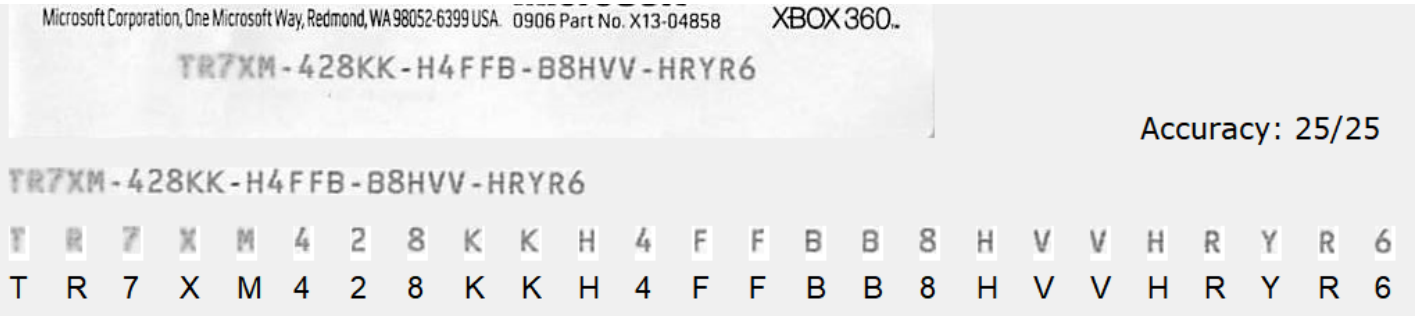

5 Wnioski

Naszym celem było osiągnięcie jak największej skuteczności w rozpoznaniu kodów z prawie 20 000 skanów (488 225 znaków). Użyliśmy czterech różnych podejść do tego problemu:

1. TesseractOCR - jest to silnik OCR, który niestety osiągnął skuteczność zaledwie kilku procent na naszych danych walidacyjnych
2. Rekurencyjna sieć neuronowa - było to podejście do problemu, które pozwalało pominąć segmentację poszczególnych liter. Niestety przez to złożoność problemu dla sieci znacznie wzrosła i nie poradziła sobie tak dobrze jak zwykła sieć neuronowa czy SVM osiągają skuteczność na poziomie 98,9195% i myląc się w 211 przypadkach
3. SVM - osiągnął skuteczność na poziomie 99,7952% myląc się tylko w 40 przypadkach
4. Sieć neuronowa - osiągnęła najlepszą skuteczność ze wszystkich metod aż 99,831% myląc się w 33 przypadkach

Podsumowując projekt można powiedzieć, że sieci neuronowe zdecydowanie sprawdzają się w problemach związanych z rozpoznawaniem tekstu ze zdjęć/skanów. Potrafiły sobie poradzić z dość trudnymi przypadkami liter (często bardzo rozmazanych). Niestety dużym problemem wciąż pozostaje efekt ćzarnej skrzynki"przez co ciężko jest efektywnie i szybko zaprojektować sieć, która rozwiąże postawiony przez nas problem.